



激光与光电子学进展
Laser & Optoelectronics Progress
ISSN 1006-4125, CN 31-1690/TN

《激光与光电子学进展》网络首发论文

题目：一种基于全局特征的行人重识别改进算法
作者：张涛，易争明，李璇，孙星
收稿日期：2020-05-26
网络首发日期：2020-07-03
引用格式：张涛，易争明，李璇，孙星. 一种基于全局特征的行人重识别改进算法[J/OL]. 激光与光电子学进展.
<https://kns.cnki.net/kcms/detail/31.1690.TN.20200702.1046.030.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

一种基于全局特征的行人重识别改进算法

张涛, 易争明*, 李璇, 孙星

天津大学电气自动化与信息工程学院, 天津 300072

摘要 当前基于全局特征的行人重识别算法主要使用交叉熵损失函数和三元组损失函数来监督网络的学习。然而, 原始三元组损失函数在增大类间距离的同时却并没有很好的优化类内距离, 为了解决这个问题, 提出了一种基于全局特征的行人重识别改进算法。算法改进了三元组损失, 在原始三元组损失中通过引入类内距离损失, 使其能够在增大类间距离的同时, 减小类内距离。通过在 Market1501, DukeMTMC-reID 和 CUHK03 数据集上的大量实验, 结果表明所提算法得到的特征具有更强的判别性, 在基于全局特征的模型中取得了最优的性能, 接近甚至超过一些基于局部特征的模型。

关键词 机器视觉; 光计算; 行人重识别; 全局特征; 三元组损失
中图分类号 TP391 文献标志码 A

An Improved Algorithm of Person Re-Identification Based on Global Features

Zhang Tao, Yi Zhengming, Li Xuan, Sun Xin

School of Electrical and Information Engineering, Tianjin University, Tianjin, 300072, China

Abstract The current person re-identification algorithms based on global features mainly use cross-entropy loss function and triplet loss function to supervise the learning of the network. However, triple loss function does not optimize the intra class variance while increasing the inter class variance. In order to solve this problem, an improved person re-identification algorithm based on global feature is proposed. The algorithm improves the triplet loss, by introducing the intra class distance loss into the original triplet loss, it can increase the inter class distance and reduce the intra class distance. Through a large number of experiments on the data sets of Markt1501, DukeMTMC-reID and CUHK03, the results show that the features obtained by the proposed algorithm are more discriminative and have the best performance in the model based on global features, approaching or even surpassing some models based on local features.

Key words machine vision; optics in computing; person re-identification; global features; triplet loss

OCIS codes 150.0155; 200.4560; 100.4995; 100.4996; 100.4999

*E-mail: yzm411522@163.com;

1 引言

行人重识别^[1]也称作行人再识别,是利用计算机视觉技术判断图像或者视频中是否存在特定行人的技术,即给定一个行人图像检索跨设备下的该行人图像,故行人重识别也可以看作是图像检索问题。行人重识别有着许多实际的应用,例如刑事侦查、视频监控以及行为理解等。

随着最近几年深度卷积神经网络的发展,基于深度卷积神经网络的行人重识别算法的性能越来越好,行人重识别也吸引了越来越多研究者的关注。当前基于深度卷积神经网络的行人重识别一般使用 GoogleNet^[2], ResNet^[3], DensNet^[4]等网络作为骨干网络来提取行人图像的特征,然后进行端到端的学习。

行人重识别网络使用的损失函数一般分为两类,一类是分类损失,一类是度量损失。基于分类损失的网络被称为 IDE (ID embedding) 模型,它将行人重识别看做一个分类任务,同 ID 的所有行人图片作为一类,并利用行人 ID 作为标签来训练行人重识别网络。如文献 [5-7] 采用分类损失提出了不同的算法模型。不同于分类损失,度量损失将行人重识别看作是一个聚类或者排序任务。在行人重识别网络中使用最广泛的度量损失是三元组损失,三元组损失的优化目标是使不同类之间的距离要比同类之间的距离至少大一个间隔。为了解决三元组损失中三元组数量过多的问题, Hermans 等^[8]提出了一个在线挖掘困难样本三元组的方法,大大减少了所需训练的三元组数量。

行人重识别算法中最理想的优化目标是最小化类内距离,最大化类间距离,然而原始的三元组损失只能将类间优化出来一个间隔,却并没有很好的优化类内距离,这使得采用原始三元组损失的全局特征行人重识别算法没有达到最优的性能,为了解决这个问题,改进了原始的三元组损失函数。通过在原始三元组损失上增加一项同类样本之间的距离损失,使改进之后的基于全局特征的算法学习出来的特征类内更紧密,类间更离散。

2 三元组损失及网络结构

2.1 三元组损失

三元组损失函数是 Schroff 等^[9]在 2015 年提出的,其最初是应用在人脸识别任务中的,由于人脸识别与行人重识别任务具有相似性,三元组损失后来也被广泛应用于行人重识别任务中来。三元组损失是一种度量损失,一个三元组包括一个锚点 (anchor), 一个正样本

(positive), 一个负样本 (negative), 因此一个三元组可以被描述为 (a, p, n) , 三元组损失使用欧式距离来表示样本之间的距离。三元组损失的学习过程如图 1 所示。




图 1 三元组损失的学习过程

Fig. 1 Learning process of triplet loss

在一个 d 维的欧氏距离空间 R^d 中, 定义 $f(x) \in R^d$ 为图像 x 在这个 R^d 空间中的映射。因此, 对于任意一个三元组 (x_i^a, x_i^p, x_i^n) , 总是希望 x_i^a 和 x_i^p 的距离要比 x_i^a 和 x_i^n 的距离要近的多, 可以表示为如下公式:

$$\|f(x_i^a) - f(x_i^p)\|_2^2 + \alpha < \|f(x_i^a) - f(x_i^n)\|_2^2, \quad (1)$$

$$\forall (f(x_i^a), f(x_i^p), f(x_i^n)) \in T, \quad (2)$$

式中: i 表示第 i 个三元组, α 表示一个强制间隔, T 表示训练集中所有的三元组的集合。

因此三元组损失可以表示为公式 (3):

$$L = \sum_i^N \max(\|f(x_i^a) - f(x_i^p)\|_2^2 - \|f(x_i^a) - f(x_i^n)\|_2^2 + \alpha, 0), \quad (3)$$

式中: N 表示所有需要训练的三元组。

2.2 改进的三元组损失

为了更好的描述三元组损失函数, 使用 $\text{dist}(a, p)$ 来表示 $\|f(x_i^a) - f(x_i^p)\|_2^2$, 使用 $\text{dist}(a, n)$ 来表示 $\|f(x_i^a) - f(x_i^n)\|_2^2$, 因此可以将公式 (3) 原始的三元组损失表示为公式 (4), 如下:

$$L = \sum_i^N \max(\text{dist}(a, p) - \text{dist}(a, n) + \alpha, 0) \quad (4)$$

对于公式(4)所示的原始三元组损失中所有经过难样本采样的三元组有如下三种情况:

- 1) $\text{dist}(a, p) - \text{dist}(a, n) + \alpha < 0$, 这种属于简单三元组, 对于这种三元组, 损失为零, 不需要训练。
- 2) $\text{dist}(a, p) > \text{dist}(a, n)$, 这种属于难样本三元组, 损失不为零, 需要训练。
- 3) $\text{dist}(a, p) < \text{dist}(a, n) < \text{dist}(a, p) + \alpha$, 这种属于半难三元组, a 和 p 的距离比 a 与 n 的距离近, 但这个距离要小于设定的间隔 α , 这种也是需要训练的样本对。

对于所有要训练的三元组，原始三元组都可以将其优化到第一种情况。对于原始的三元组损失满足第一种情况损失就为零，这个三元组就不需要训练。对于三元组损失，最理想的情况是 $\text{dist}(a, p)$ 的距离无限接近于零， $\text{dist}(a, n)$ 的距离无限大，即网络将同一个 ID 的图像映射到嵌入空间的一个点上，将不同人的图像映射到无穷远处。但是通过分析第一种情况，原始的三元组损失并不能很好的约束同一个 ID 之间的距离。对于第一种情况，现在考虑两种情形：① $\text{dist}(a, p) = 10, \text{dist}(a, n) = 11, \alpha = 0.3$ ，则有 $10 - 11 + 0.3 = -0.7 < 0$ ，这种情况是满足公式的。② $\text{dist}(a, p) = 1, \text{dist}(a, n) = 11, \alpha = 0.3$ ，则有 $1 - 11 + 0.3 = -9.7 < 0$ ，这种情况同样满足公式，比较①和②显然②要更好，因为在②中的 $\text{dist}(a, p)$ 要比 $\text{dist}(a, n)$ 小的多，对于这两种情况都能使得原始的三元组损失为零，并不会再优化了。于是针对这个问题，提出了改进的三元组损失函数，如公式（5）所示：

$$L = \sum_i^N \max(\text{dist}(a, p) - \text{dist}(a, n) + \alpha, 0) + \lambda \times \text{dist}(a, p) \quad (5)$$

在原始的三元组损失上增加了一项 $\lambda \times \text{dist}(a, p)$ ，并引入了一个参数 λ 。改进后的三元组损失，在满足第一种情况的时候，其损失值为类内距离，在不优化类间距离的时候，需要优化类内距离，使其类内距离更小。通过引入参数可以控制 λ 对于类内距离的优化程度， λ 过大或者过小都可能对网络学习出来的特征产生影响。

2.3 基于全局特征的网络结构

模型采用了与文献[10]相同的网络结构，以 Resnet50 作为模型的骨干网络，去掉最后一层全连接层，并将 ResNet50 网络每个 block 块的最后一个卷积层的步长设置为 1，以增大网络输出的特征图，从而获得更多的特征信息。从 Resnet50 网络输出的特征图经过自适应平均池化得到 2048 维的特征，然后经过两个分支，一个分支计算三元组损失和中心损失，另一个分支将 2048 维度特征经过一个 BNNeck 层（去掉偏置的批标准化层）和一个全连接层，计算带标签平滑的交叉熵损失，最后将这三种损失的值加起来，得到最终的损失。其中交叉熵损失用于分类，中心损失使网络学习出来一个类中心，优化类内距离，三元组损失同时优化类内和类间距离，三种损失联合使用能够更好地使网络优化类内和类间距离。




图 2 网络模型结构
Fig. 2 Structure of network model

3 实验与结果分析

3.1 数据集及评价指标

实验是在 Market1501^[11], DukeMTMC-reID^[12]和 CUHK03^[13]三个主流的行人重识别数据集上进行的。在分析实验结果之前, 首先对三个实验数据集进行介绍。

Market1501 数据集是在清华大学校园采集的。数据集一共包含有 1501 个行人, 通过 6 个不同的摄像头采集而来的, 行人裁剪框是通过 DPM 检测器自动检测而来的。整个数据集被分为训练集和测试集, 训练集包含 751 个行人, 12936 张图片。测试集包含 750 个行人, 19732 张图片, 其中 3368 张图片作为检索图片, 15913 张图片作为被检索图片。评估方法根据每个行人的检索图片数量分为两种方法, 一种是每个行人只有一张图片用于检索, 另外一种是每个行人有多张图片用于检索, 本实验采用的是第二种评估方法。

DukeMTMC-reID 数据集是 DukeMTMC 数据集的子集, 它是在杜克大学校园内采集的。数据集一共包含 1404 个行人, 通过 8 个不同的摄像头采集而来。不同于 Market1501 数据集, DukeMTMC-reID 数据集的行人裁剪框是人工标注的。训练集包含 702 个行人, 16522 张图片作为训练数据。测试集为剩下的 702 人, 2228 张图片作为检索图片, 17661 张图片作为被检索图片。与 Market1501 对比, DukeMTMC-reID 对于行人重识别算法是一个更有挑战性的数据集, 因为它包含了更多的遮挡和重叠。

CUHK03 数据集是在香港中文大学采集的。数据集一共包含 1467 个行人的 14097 张图片。每个行人会被两个不同的摄像头采集。该数据集提供两种不同的行人裁剪框, 一种是手工标注的, 另一种是由 DPM 检测器自动检测的。对于 CUHK03 数据集使用文献[14]中提出的一个类似于 Market1501 数据集的简化的评估方法, 并将 CUHK03 人工标注的数据集称为 CUHK03-Labeled, 检测标注的数据集称为 CUHK03-Detected。

实验评价指标采用行人重识别算法中最常用的累计匹配曲线 (CMC) 中的首位匹配率 (rank1) 和均值平均精度 (mAP) 来对模型性能进行评估。

3.2 实验环境和参数设置

实验环境为配有 2.20 GHz Xeon E5-2630 v4 CPU 和 GTX 2080TI GPU 的设备。模型基于 Pytorch 深度学习框架进行构建, 网络训练时候使用 Resnet50 在 ImageNet 上的预训练模型。

输入图像的大小为 256×128 ，数据增强使用了随机翻转，随机裁剪和随机擦除方法。模型使用 Adam 优化器来优化网络参数,对于 Adam 优化器超参数设置为 $\varepsilon = 10^{-8}, \beta_1 = 0.9, \beta_2 = 0.9$ ，初始学习率设置为 3.5×10^{-4} ，并采用了文献[3]中预热的学习率调整策略，并在第 40 和 70 次迭代的时候将学习率分别减小到 3.5×10^{-5} 和 3.5×10^{-6} ，每次训练共迭代 120 次。

3.3 参数 λ 对模型性能影响

参数 λ 影响着模型对类间距离的优化，为了分析不同的权重 λ 对模型性能的影响，首先选取了 $\lambda=0.1, 0.3, 0.5, 0.7, 0.9, 1.0$ 共 6 个不同的值，通过在 Market1501 和 DukeMTMC-reID 数据集上的两组对比实验来说明超参 λ 对实验结果的影响。

表 1 和图 3 给出了在 Market1501 和 DukeMTMC-reID 对本算法进行实验得到的结果。从表 1 中可以看出，在 Market1501 数据集上，当 $\lambda=0.1$ 和 $\lambda=0.3$ 时，模型的性能相似，当 $\lambda=1.0$ 的时候模型的性能最差；在 DukeMTMC-reID 数据集上，当 $\lambda=0.3$ 时，模型性能最好， $\lambda=1.0$ 的时候模型的性能最差。从图 3 中可以看出参数 λ 主要影响 mAP，对于 rank1 的影响明显要小于对于 mAP 的影响，对于 rank1 影响较小的主要原因是模型性能达到一定程度时，最容易匹配的图像已经全部被找到。也可以看出参数 λ 对于模型性能的影响在两个数据集上具有一致性，即在 $\lambda < 0.3$ 的时候，模型的性能较好，在 $\lambda > 0.3$ 的时候模型的性能随着 λ 增大也越差。因此，从实验结果说明正确地选择参数 λ 的值对于模型性能的提升有着很大的影响。

表 1 不同参数设置下的性能对比
Table 1 Performance contrast chart with different parameter settings

λ	Market1501		DukeMTMC-reID	
	mAP	rank1	mAP	rank1
0.1	87.4	94.8	78.2	88.0
0.3	87.5	94.7	78.4	88.2
0.5	87.1	94.7	77.8	87.7
0.7	86.8	94.7	77.3	87.8
0.9	86.4	94.6	76.7	87.6
1.0	86.3	94.7	76.2	87.5

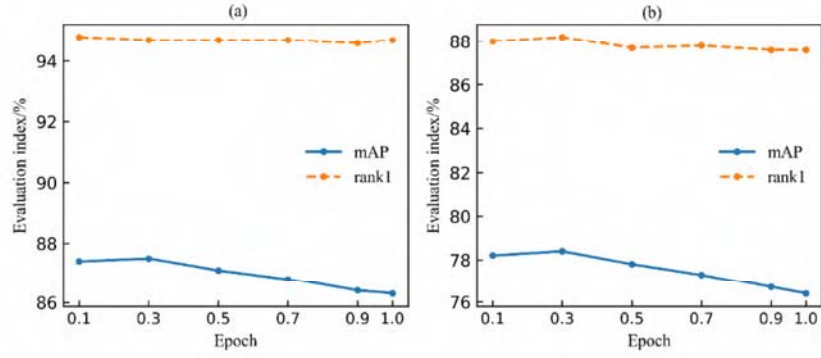


图 3 不同 λ 下模型性能。(a) Market1501 的实验结果。(b) DukeMTMC-reID 实验结果。

Fig. 3 Model performance under different λ . (a) Experimental results of Martket1501. (b) Experimental results of DukeMTMC-reID.

3.4 与原始三元组损失对比

在 Market1501 和 DukeMTMC-reID 数据集上分别用原始三元组损失的模型和改进之后的模型进行训练，实验中除三元组损失不同外，保持其他的设置完全一致，并联合中心损失和交叉熵损失一起训练，每迭代 5 次计算一下模型的性能指标，实验结果如图 4。从图 4 可以看出，在原始模型上，两个数据集在前 40 次迭代都出现了震荡，并且模型在迭代 80 次之后才渐渐稳定达到最佳的性能，而改进之后的模型上，训练曲线更加平滑，模型震荡较小，并且在迭代 60 次的时候模型就渐渐达到了稳定的最佳性能。对比实验表明，改进后的算法训练时抖动小，并且比原始模型能在更快的时间收敛到最佳的性能。

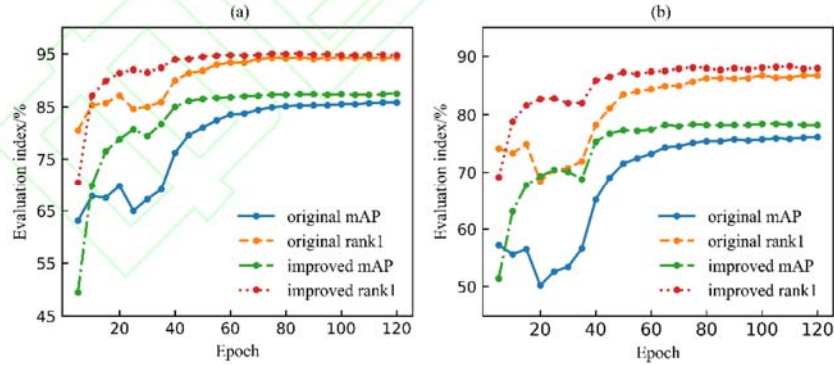


图 4 与原始模型对比实验结果。(a) Market1501 在两个模型上实验结果对比；(d) DukeMTMC-reID 在两个模型上实验结果对比；

Fig. 4 Experimental results compared with the original model. (a) Comparison of experimental results of Market151 on two models; (b) Comparison of experimental results of DukeMTMC-reID on two models;

3.5 与其他主流算法比较

为了进一步说明改进后算法的有效性，在 Market1501、DukeMTMC-reID 和 CUHK03 数

数据集上进行实验，并与基于全局特征和局部特征的两大类模型进行对比，结果如表 2 和表 3 所示，表中“-”表示对应方法未在数据集上实验。与基于全局特征的行人重识别算法相比，所提算法在三个数据集上都取得了最优的性能。与基于局部特征的行人重识别算法相比，在 Market1501 上，所提算法超过了 MGN 算法，略低于 Pyramid 算法。在 DukeMTMC-reID 上，所提算法性能与 MGN 相似，也略低于 Pyramid 算法。在 CUHK03 上，所提算法在 Labeled 数据集上接近 MGN 算法性能，但是在 Detected 数据集上所提算法低于 MGN。其原因是 Detected 数据集属于自动标注要比 Labeled 手工标注有更多的遮挡可折叠，对于算法更有挑战。

表 2 所提算法在 Market1501 和 DukeMTMC-reID 上与其他先进算法的对比
Table 2 Comparison between proposed algorithm and other advanced algorithms on Market1501 and DukeMTMC-reID

Algorithm		Market1501		DukeMTMC-reID	
		mAP	Rank1	Map	Rank1
Stripe-based	AlignedReID++ ^[15]	77.7	90.6	67.4	81.2
	SCPNet ^[16]	75.2	91.2	62.6	80.3
	PCB+RPP ^[17]	81.6	93.8	69.2	83.3
	Pyramid ^[18]	88.2	95.7	79.0	89.9
	HPM ^[19]	82.7	94.2	74.3	86.6
	MGN ^[20]	86.9	95.7	78.4	88.7
Global feature	IDE ^[21]	59.9	79.5	-	-
	SVDNe ^[22]	62.1	82.3	56.8	76.7
	TriNet ^[9]	69.1	84.9	-	-
	AWTL ^[23]	75.7	89.5	63.4	79.8
	Baseline ^[7]	85.9	94.5	76.4	86.4
	Ours	87.5	94.7	78.4	88.2

表 3 所提算法在 CUHK03 上与其他先进算法的对比
Table 3 Comparison between proposed algorithm and other advanced algorithms on CUHK03

Algorithm		Labeled		Detected	
		mAP	rank1	mAP	rank1
Stripe-based	MGN ^[20]	67.4	68.0	66.0	68.0
	PCB+RPP ^[17]	-	-	57.5	63.7
Global feature	MLFN ^[24]	49.2	54.7	47.8	52.8
	HA-CNN ^[26]	41.0	44.4	38.6	41.7
	SVDNet ^[22]	37.8	40.9	37.3	41.5
	PAN ^[25]	35.0	36.9	34.0	36.3
	IDE ^[21]	21.0	22.2	19.7	21.3
	Ours	67.3	69.9	63.8	65.4

4 结 论

本文提出了一种基于全局特征的行人重识别改进算法。算法改进了三元组损失函数, 通过在三元组损中引入一项正样本之间的距离损失, 使改进后的算法能够更好的优化样本之间的距离, 学习出来的特征更具判别性, 进一步提高了重识别的精度。通过在 Market1501, DukeMTMC-reID 和 CUHK03 数据集上的大量实验, 表明在所有的基于全局特征的模型中取得了最优的性能。

参考文献

- [1] Luo H, Jiang W, Fan X, et al. A Survey on Deep Learning Based Person Re-identification[J]. Acta Automatica Sinica, 2019, 45(11): 2032-2049.
罗浩, 姜伟, 范星, 等. 基于深度学习的行人重识别研究进展[J]. 自动化学报, 2019, 45(11): 2032-2049.
- [2] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]// 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 7-12, Boston, USA. New York: IEEE, 2015: 1-9.
- [3] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]// 2016 IEEE Conference on Computer Cision and Pattern Recognition (CVPR), June 27-30, Las Vegas, USA. New York: IEEE, 2016: 770-778.
- [4] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), July 22 -25, Honolulu, Hawaii, USA. New York: IEEE, 2017: 4700-4708.
- [5] Chen B, Zha Y F, Li Y Q, et al. Person Re-Identification Based on Convolutional Neural Network Discriminative Feature Learning[J]. Acta Optica Sinica, 2018, 38(7): 0720001.
陈兵, 查宇飞, 李运强, 等. 基于卷积神经网络判别特征学习的行人重识别[J]. 光学学报, 2018, 38(7): 0720001.
- [6] Pan T, Li W G. Person Re-Identification Based on Feature Stitching[J]. Laser & Optoelectronics Progress, 2019, 56(16): 162001
潘通, 李文国. 基于特征拼接的行人重识别[J]. 激光与光电子学进展, 2019, 56(16): 162001.
- [7] Xu L Z, Peng L. Person Reidentification Based on Multiscale Convolutional Feature Fusion[J]. Laser & Optoelectronics Progress, 2019, 56(14): 141504.
徐龙壮, 彭力. 基于多尺度卷积特征融合的行人重识别[J]. 激光与光电子学进展, 2019, 56(14): 141504.
- [8] Hermans A, Beyer L, Leibe B. In defense of the triplet loss for person re-identification[J/OL]. (2017-5-17) [2020-4-20]. <https://arxiv.org/abs/1703.07737>.
- [9] Schroff F, Kalenichenko D, Philbin J. FaceNet: A unified embedding for face recognition and clustering[C]// 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 7-12, Boston, USA. New York: IEEE, 2015: 815-823.
- [10] Luo H, Jiang W, Gu Y, et al. A Strong Baseline and Batch Normalization Neck for Deep

- Person Re-identification[J]. IEEE Transactions on Multimedia, 2019.
- [11] Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C]// IEEE International Conference on Computer Vision (ICCV), December 13-16, Santiago, Chile. New York: IEEE, 2015: 1116-1124.
 - [12] Ristani E, Solera F, Zou R, et al. Performance measures and a data set for multi-target, multi-camera tracking[C]// European Conference on Computer Vision Workshop (ECCVW), October 8-10 and 15-16, Amsterdam, The Netherlands. 2016: 17-35.
 - [13] Li W, Zhao R, Xiao T, et al. DeepReID: Deep Filter Pairing Neural Network for Person Re-identification[C]// IEEE Conference on Computer Vision and Pattern Recognition. Jun 24-27, Columbus, Ohio. New York: IEEE, 2014: 152-159.
 - [14] Zhong Z, Zheng L, Cao D, et al. Re-ranking Person Re-identification with k-Reciprocal Encoding[C]// IEEE Conference on Computer Vision and Pattern Recognition (CVPR), July 22 -25, Honolulu, HI. New York: IEEE, 2017: 3652-3661.
 - [15] Luo H, Jiang W, Zhang X, et al. Alignedreid++: Dynamically matching local information for person reidentification[J]. Pattern Recognition, 2019, 94: 53-61.
 - [16] Fan X, Luo H, Zhang X, et al. Scpnnet: Spatial-channel parallelism network for joint holistic and partial person re-identification[C]// Asian Conference on Computer Vision. Dec 4-6, Perth Australia. Cham: Springer, 2018: 19-34.
 - [17] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]// European Conference on Computer Vision (ECCV), September 8-14, Munich, Germany. Cham Springer: 2018, 11208, 501--518.
 - [18] Zheng F, Deng C, Sun X, et al. Pyramidal person re-identification via multi-loss dynamic training[C]// IEEE Conference on Computer Vision and Pattern Recognition. June 16-20, Long Beach, CA, USA. New York: IEEE, 2019: 8514-8522.
 - [19] Fu Y, Wei Y, Zhou Y, et al. Horizontal Pyramid Matching for Person Re-identification[C]// The Thirty-Third AAAI Conference on Artificial Intelligence (AAAI-19), January 27-February 1, Honolulu, Hawaii, USA. California: AAAI, 2019: 8295-8302.
 - [20] Wang G, Yuan Y, Chen X, et al. Learning discriminative features with multiple granularities for person re-identification[C]// ACM Multimedia Conference on Multimedia Conference. October 22-26, 2018, Seoul, Republic of Korea. New York: ACM, 2018: 274-282.
 - [21] Zheng Z, Zheng L, Yang Y. A discriminatively learned cnn embedding for person reidentification[J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM), 2018, 14(13): 1-20.
 - [22] Sun Y, Zheng L, Deng W, et al. SVDNet for pedestrian retrieval[C] IEEE International Conference on Computer Vision (ICCV), October 22-29, 2017, Venice, Italy. New York: IEEE, 2017: 3820-3828.
 - [23] Ristani E, Tomasi C. Features for multi-target multi-camera tracking and re-identification[C]// IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 18-22, 2018, Salt Lake City, UT, USA. New York: IEEE, 2018: 6036-6046.
 - [24] Chang X, Hospedales T, Xiang T. Multi-Level Factorisation Net for Person Re-Identification[C]// IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 18-22, 2018, Salt Lake City, UT, USA. New York: IEEE, 2018: 2109-2118.
 - [25] Zheng Z, Zheng L, Yang Y. Pedestrian alignment network for large-scale person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2019,

29(10), 3037-3045.

- [26] Li W, Zhu X, Gong S. Harmonious attention network for person re-identification[C]// IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 18-22, 2018, Salt Lake City, UT, USA. New York: IEEE, 2018: 2285-2294.



网络首发:

标题: 一种基于全局特征的行人重识别改进算法

作者: 张涛, 易争明, 李璇, 孙星

收稿日期: 2020-05-26

录用日期: 2020-06-09

DOI: 10.3788/lop57.241503

引用格式:

张涛, 易争明, 李璇, 孙星. 一种基于全局特征的行人重识别改进算法[J]. 激光与光电子学进展, 2020, 57(24): 241503.

网络首发文章内容与正式出版的有细微差别, 请以正式出版文件为准!

您感兴趣的其他相关论文:

基于机器视觉的包装袋缺陷检测算法研究与应用

李丹 白国君 金媛媛 童艳

沈阳城市建设学院信息与控制工程系, 辽宁 沈阳 110167

激光与光电子学进展, 2019, 56(9): 091501

基因表达式编程优化的色调保持低照度图像增强

贾新宇 李婷婷 江朝晖 刘海秋 饶元

安徽农业大学信息与计算机学院, 安徽 合肥 230036

激光与光电子学进展, 2019, 56(9): 091502

基于深度学习的图像显著区域检测

纪超 黄新波 曹雯 朱永灿 张烨

西安工程大学电子信息学院, 陕西 西安 710048

激光与光电子学进展, 2019, 56(9): 091007

面向皮革缺陷检测的离轴LED曲面阵列照明设计

王德宇 王雪琨 于文文 曹建军 钱维莹 高淑梅

江南大学理学院江苏省轻工光电工程技术研究中心, 江苏 无锡 214122

激光与光电子学进展, 2019, 56(8): 082202

结合函数映射与循环一致性约束的模型簇对应关系计算

杨军 雷鸣

兰州交通大学电子与信息工程学院, 甘肃 兰州 730070

激光与光电子学进展, 2019, 56(8): 081005