



安徽大学学报(自然科学版)

Journal of Anhui University(Natural Science Edition)

ISSN 1000-2162,CN 34-1063/N

《安徽大学学报(自然科学版)》网络首发论文

题目: 基于属性擦除与多分支网络的行人重识别
作者: 王年, 刘天翔, 汪曙光, 唐俊
收稿日期: 2020-05-10
网络首发日期: 2020-06-18
引用格式: 王年, 刘天翔, 汪曙光, 唐俊. 基于属性擦除与多分支网络的行人重识别[J/OL]. 安徽大学学报(自然科学版).
<https://kns.cnki.net/kcms/detail/34.1063.N.20200617.1622.012.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于属性擦除与多分支网络的行人重识别

王 年¹, 刘天翔¹, 汪曙光^{2*}, 唐 俊¹

(1. 安徽大学 电子信息工程学院, 安徽 合肥 230601; 2. 清华大学 合肥公共安全研究院, 安徽 合肥 230601)

摘 要: 行人重识别易受到物体不同程度遮挡的影响. 针对物体遮挡以及网络特征提取能力不强的问题, 提出一种基于属性擦除与多分支网络的行人重识别的方法. 该方法利用行人的包属性标签随机擦除进行数据增广. 网络结构由 ResNet-50 基础网络与全局、局部卷积两个分支结构组成. 全局卷积分支提供全局特征, 局部卷积分支提供丰富的细粒度信息. 通过两个分支的特征级联提升网络的特征提取能力. 在 Market-1501、DuckMTMC-reID 数据集上, 证明论文方法具有较好的效果.

关键词: 行人重识别; 过拟合; 随机擦除; 数据增广

中图分类号: TP391.4

文献标志码: A

文章编号: 1000-2162(2020)03-0001-04

Person re-identification based on attribute erasing and multi-branch network

WANG Nian¹, LIU Tianxiang¹, WANG Shuguang^{2*}, TANG Jun¹

(1. School of Electronics and Information Engineering, Anhui University, Hefei 230601, China;

2. Hefei Institute for Public Safety Research, Tsinghua University, Hefei 230601, China)

Abstract: Person re-identification is susceptible to different degrees of occlusion. A method based on attribute label random erasing and multi-branch network pedestrian recognition is proposed for the problem of object occlusion and network feature extraction. The method utilizes pedestrian's package attribute tag random erasing for data augmentation. The network structure consists of two basic branches: ResNet-50 basic network and global and local convolution. The global convolution branch provides global features, and the local convolution branch provides rich, fine-grained information. The feature extraction capability of the network is enhanced by the feature cascade of the two branches. The results on the Market-1501 and DuckMTMC-reID datasets show that the proposed method has a good effect.

Keywords: person re-identification; overfitting; random erasing; data augmentation

行人重识别(person re-identification, 简称 Re-ID)是利用计算机视觉技术判断图像或者视频序列中是否存在特定行人的技术, 在人员追踪、走失查询等应用中具有重要意义. 由于实际视频监控场景的复杂性(如姿势、衣物、遮挡及背景杂乱等), 行人重识别的效果会受到影响. 近年来, 行人重识别已成为

收稿日期: 2020-05-10

基金项目: 国家重点研发计划重点专项(2018YFC0807302); 国家自然科学基金资助项目(61772032); 安徽省科技重大专项(17030901016)

作者简介: 王年(1966—), 男, 安徽和县人, 安徽大学教授, 博士生导师, 博士; * 汪曙光(通信作者), 清华大学副教授, 博士, E-mail: wangshuguang@gsafety.com.

研究的热点问题,主要内容可以分为以下两个方面:①图像特征的提取;②对姿势、衣物、遮挡及背景杂乱等干扰因素进行处理.目前基于深度学习的方法是解决以上问题的主要方法,该方法主要是利用卷积神经网络(convolutional neural networks,简称 CNN)进行处理,具有较好的可辨性、稳健性以及较快的处理速度.通过全局特征获得一些显著信息,并以此辨别是否存在检测目标,提升检测指标的 Rank-1 正确率和平均精度,是近期常用的行人重识别方法^[1-4].由于在复杂的监控场景中,捕获图像特征的高复杂度通常会限制全局特征的学习,并且由于行人重识别训练数据集的大小有限、多样性较弱,因此在学习全局特征中很容易忽略一些重要或不常见的细节信息,这使得全局特征对那些特征不明显或特征差异性不大的识别任务效果不理想.

为了解决上述问题,论文提出了一种基于属性标签随机擦除与多分支网络的行人重识别方法,该方法先对带有包属性标签的行人图像进行随机擦除进行数据增广,然后通过基础网络和两个分支网络进行特征提取.在局部分支网络中,针对每幅特征图均分的 6 个水平条纹,分别提取每个条纹中细粒度信息来辅助全局特征能更好的识别指定行人.论文由每个均分的条纹为行人重识别提供细粒度的信息.局部分支能够集合每个条纹中特定的判别信息,同时可以消除剩余条纹信息的影响.全局分支关注显著信息,用于提供全局特征.通过两个分支的特征级联来提升特征学习的能力.

论文使用的是端到端的方法,易于模型的训练和数据测试,通过在 Market-1501, DukeMMC-reID 数据集上实验,验证了论文方法具有较高的准确性和鲁棒性.

1 相关工作

深度学习可使行人重识别的性能比传统机器学习方法有大幅度地提升.文献[5-6]将深度学习引入行人重识别,结合身体局部特征提取,取得比传统机器学习更好的识别效果.文献[7]提出一种基于 K 阶导数编码的方式,对需要检测的待查询集图像进行重排序,进一步提升识别效果.文献[8]通过在训练阶段采用对齐的方法,使网络性能得到提高.文献[9]也采用类似的方法将输入的特征图在垂直方向进行若干等分的划分,采用图像的局部特征图,有利于提升网络识别的性能.因此,论文使用局部分支网络提取分割特征图的更高层语义特征,以提高识别性能.

在深度神经网络模型的训练阶段,分类损失函数(softmax loss)^[1]是常用的分类损失函数之一,它在分类任务中表现出很好的效果,与其他损失函数相结合使用可以进一步提高分类效果^[10].度量学习也是常见的解决图像检索问题的有效方法之一,习常使用对比损失^[9]和三元组损失函数(Triplet Loss)^[11]在最大化类间距离与最小化类内距离任务中,常使用孪生网络^[12]和对比损失函数.三元组损失函数是通过减小或限制同类样本之间的距离,同时增大不同类别样本之间的距离.三元组损失函数在不断的研究过程中也不断地被改进^[13].为了能够更好地解决度量学习中的性能问题,论文采用分类损失函数和困难三元组损失函数(Hard Triplet Loss)相结合作为损失函数.

2 基于属性擦除与多分支网络的行人重识别

2.1 利用属性标签进行随机擦除数据增广

利用行人的属性标签进行模型训练的方法也是 Re-ID 研究方向之一,Market-1501 的属性标签如图 1 中(a)所示,其中标注性别(男、女)、头发长度(长、短)、是否背包(是、否)、是否提手提包(是、否)等 27 个属性标签; DuckMTMC-reID 的属性标签如图 1 中(b)所示,其中标注性别(男、女)、是否背包(是、否)、是否提手提包(是、否)等 23 个属性标签.论文在属性标签中把提袋、背包、提包作为数据集属性标签中的包属性标签随机擦除进行数据增广.

在深度学习中,如果没有充足的数据量,则模型易出现过拟合的现象,通常需要通过数据增广来提升网络的泛化能力.数据增广一般有 8 种方法:旋转或反射变换、翻转变换、缩放变换、平移变换、尺度变换、对比度变换、噪声扰动和颜色变换.但由于网络模型的泛化能力有限,不能很好地去识别带有遮挡物的行人图像,而行人遮挡物最常见的就是所携带的包,为了提升网络的鲁棒性,可以对带有包属性标签的行人图像进行随机擦除.

Attribute	Label
gender	2
hair	2
up	2
down	2
clothes	1
hat	1
backpack	1
bag	1
handbag	2
age	2
upwhite	2
downred	2

(a) Market-1501

Attribute	Label
gender	2
top	1
backpack	2
bag	1
hat	1
boots	2
shoes	1
handbag	1
upblack	2
downblue	1

(b) DuckMTMC-reID

图1 数据集上的属性标签示例(gender这一属性采用1表示男性、2表示女性)

随机擦除是一种新颖的数据增广^[8](数据预处理)方法,论文采用包属性随机擦除的数据增广方法,即随机擦除那些有包属性标签的行人图像,若行人图像有包属性标签则对其进行随机擦除,否则不进行擦除,降低包对行人重识别的影响.在随机擦除的过程中,为了避免擦除掉行人头部等重要信息,只对中间部位进行随机擦除,产生不同大小、位置的擦除区域,提升网络提取特征的表达能,这样不仅降低过拟合的风险而且提升模型的鲁棒性.具体过程如下:

(1) 随机选择一个特定的矩形区域 I_e , 然后通过把原有的像素值置为 0 的方式进行像素擦除. 其中图像的面积

$$S = WH, \quad (1)$$

其中: W 为行人图像的宽, H 为行人图像的高.

随机擦除矩形框的高和宽为

$$H_e = \sqrt{S_e \times R_e}, \quad (2)$$

$$W_e = \sqrt{\frac{S_e}{R_e}}, \quad (3)$$

其中: S_e 为擦除的矩形框面积, R_e 为擦除矩形框的高宽比, H_e 为擦除矩形框的高, W_e 为擦除矩形框的宽.

(2) 在图像中随机选择一个点 $P(x_e, y_e)$, 其中所选的点必须满足以下条件

$$x_e + W_e \leq W, \quad (4)$$

$$y_e + H_e \leq H. \quad (5)$$

(3) 选择合适的点构成可擦除矩形框. 该实验选定 $(x_e, y_e, x_e + W_e, y_e + H_e)$ 作为矩形区域, 将其带有包属性标签的行人图像的像素值置为 0. 最后, 将图片输出, 图片经过预处理后的结果如图 2 所示.



(a) 带有包属性标签进行擦除后的图像



(b) 未随机擦除的图像

图2 图像经过预处理后的效果对比图

2.2 网络结构

论文选择 ResNet-50 作为基础网络,该网络具有架构简单、性能较好的优点. 利用一个全局分支和一个局部分支对基础网络进行改进,如图 3 所示.

首先大小为 384×128 的图像通过 ResNet-50 的前 4 个阶段进行特征学习,为了保持最后特征图的尺寸,去除前 4 个阶段的下采样,第 4 个阶段输出特征图的维度是 $2048 \times 24 \times 8$,接下来分成两个分支.

在局部分支中,将特征图平均分成 P 个水平条纹^[9] ($P=6$),然后在各条纹上应用全局均值池化,得到 P 个 2048×1 维度的特征向量,再使用 1×1 卷积核降维,获得 256×1 维的特征向量. 最后,对每个条纹对应的特征向量,分别采用 N 类别(训练集 ID 数目)的分类损失函数训练得到 P 个 $N - \text{ID}_s$ 的分类器. 每个分类器都使用全连接层和顺序交叉熵层实现. 在训练期间,由分类损失函数监督每个分类器预测输入图像的身份.

在全局分支中,首先采用全局平均池化将特征图池化为 2048×1 维的特征,然后采用 1×1 卷积核降维到 512×1 ,最后采用分类损失函数进行 ID 分类及困难三元组损失函数的监督.




图 3 网络结构示意图

2.3 损失函数

在图像识别任务中,通常将其视为一个多类别的分类问题,而在多分类任务中最常见的就是分类损失函数. 分类损失函数表示为

$$L = - \sum_{i=1}^N y_i \log S_i, \quad (6)$$

其中: L 代表损失函数, N 代表类别数; S_i 代表 Softmax 的输出向量 S 的第 i 个值,表示样本属于第 i 个类别的概率; y_i ($1 \leq i \leq n$) 为标签,真实标签对应的位置 y_i 的值为 1,其余都是 0,结果为

$$L = - \log S_i. \quad (7)$$

在行人重识别模型训练过程中将每个行人 ID 视为一类,训练特征提取网络,为每幅图像预测一个所属类别. 与传统的分类损失函数不同,为了得到更好的模型,该章采用文献[19]中改良后的分类损失函数. 改良后的分类损失函数表示为

$$L_{\text{softmax}} = - \sum_{i=1}^N \log \frac{e^{w_{y_i}^T f_i}}{\sum_{k=1}^C e^{w_k^T f_i}}, \quad (8)$$

其中: α 为第 ID 个学习特征, ID 对应于第 ID 类的权重向量, N 和 C 分别为训练过程中的批次大小和类别数量.

三元组损失函数虽然经常用于行人重识别的任务中,但是有很大的缺陷,如重复学习大量冗余信息,模型并没有学习到太多有用的信息,而且随着数据集的增大,模型训练的时间也会大幅度的增加.

$$L = - \sum_{i=1}^{PK} [\alpha + \|f_a^{(i)} - f_p^{(i)}\|_2 - \|f_a^{(i)} - f_n^{(i)}\|_2]. \quad (9)$$

三元组损失函数任务的关键部分就是困难三元组的学习,通过学习两个长得特别像的人(困难负样本)细粒度信息,或者学习同一个人(困难正样本)在不同环境下不同姿势的特征信息,这样在训练模型的过程中能更加有效. 论文使用困难三元组损失函数,这是一个三元组损失函数的改进版本,具体损失函数如下

$$L_{\text{triplet}} = - \sum_{i=1}^P \sum_{a=1}^K [\alpha + \max_{p=1 \dots K} \|f_a^{(i)} - f_p^{(i)}\|_2 - \min_{\substack{n=1 \dots K \\ j=1 \dots P \\ j \neq i}} \|f_a^{(i)} - f_n^{(i)}\|_2], \quad (10)$$

其中: $f_a^{(i)}$, $f_p^{(i)}$, $f_n^{(i)}$ 是从锚样本(anchor)、正样本(positive)、负样本(negative)中接收的特征; α 是边距超参数,用于调节不相同 ID 样本和相同 ID 样本距离的差异. 和锚样本具有相同 ID 的样本为正样本,反之为负样本. 如图 4 所示,即随机选择 K 个不同身份的人,每个身份的人随机选择 2048×1 张图像,待训练的三元组由正样本中差异最大的样本和负样本中差异最小的样本分别组成正负样本.

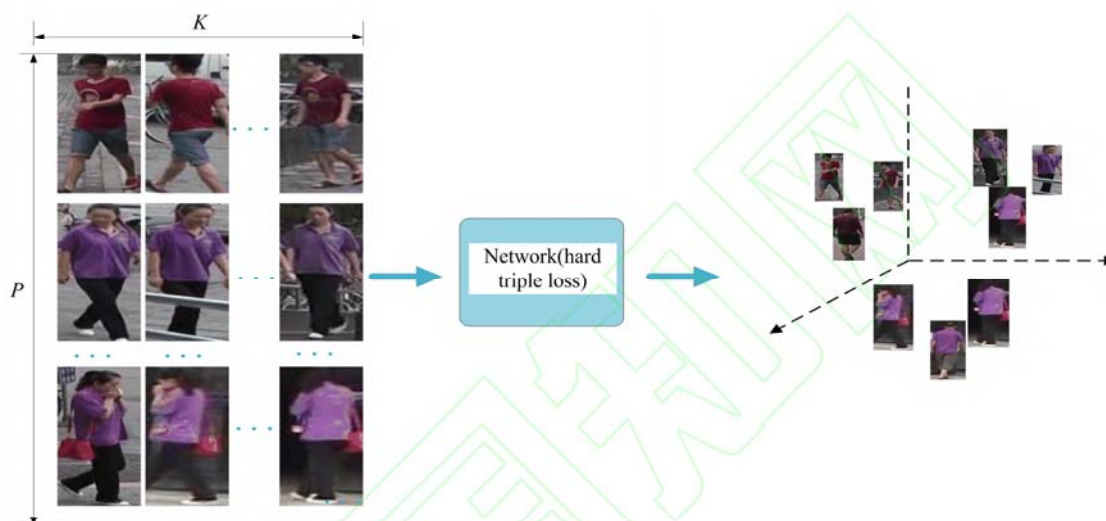


图 4 困难三元组示意图

论文在训练模型的过程中使用了深度学习中最常用的两个损失函数用作训练阶段的损失函数,即用于分类的分类损失函数和困难三元组损失函数. 论文在不同的分支上的损失函数不是完全相同的. 首先在局部分支中,只使用分类损失函数,通过实验发现,直接使用三元组损失函数达不到理想的效果,原因是论文将图像均匀分成 6 个水平条纹,最理想的情况是不同图像之间相同的位置代表相同的身体部位,但是对于实际的图像而言,计算不同背景之间的距离并没有任何意义,使用这样的三元组进行训练模型可能会使整个模型崩溃. 因此,论文在全局分支中使用的是分类损失函数和困难三元组损失函数的结合.

3 实验

3.1 数据集

论文实验选用的数据集是 Market-1501 和 DukeMMC-reID. Market-1501 数据集分别从 6 个不同摄像头拍摄到 1 501 个不同行人的图像,然后用 DPM(deformable parts models)算法检测行人的边界框并进行自动裁剪. 由于检测过程中存在误差,这样使数据集更加接近实际应用情况. 将整个数据集分为训练集和测试集,其中训练集包含 751 人的 12 936 张图像,测试集由 750 人的 3 368 张查询图像和 19 732 张候选图成. DukeMMC-reID 数据集由 8 个相机拍摄的 1 812 行人的 36 411 张图像组成,通过手绘边界框将行人从中裁剪出来,其中训练集由 702 人的 16 522 张图像组成,测试集由 702 人的 2 228 张查询图像和 17 661 张候选图像组成. 训练图像和测试图像中人物身份不重叠. 在评估中,有两种查询模式:单查询模式和多查询模式,具体的选择取决于同一身份的图像数量,论文所使用的是单查询模式. 选择首位命中率(Rank-1 Accuracy)和平均精度均值(mean average precision,简称 mAP)来作为衡量

Re-ID 的指标.

图 5 为查询图像排名前 10 的次序示意图. 由图 5 可见, 对于每张查询图像, 论文将所有候选图像按其到查询图像的欧式距离进行升序排列, 带有绿色边框的图像属于正确标识, 带有红色边框的图像则属于错误标识.




图 5 查询图像排名前 10 的次序示意图

3.2 实验过程

为了从行人图像中捕获更详细的信息, 根据文献[9]的方法将输入图像的大小调整为 384×128 . 论文使用在 ImageNet 上预训练的 ResNet-50 的权重^[7]来初始化网络. 在训练阶段中, 通过将水平翻转、归一化和随机擦除训练数据集进行数据增广. 每个训练批次中随机抽取 P 个 ID 的人, 每个人随机抽取 K 张图像. 设置 $P=16$ 和 $K=4$ 来训练模型, 在所有实验中间距为 1.2. 论文选择动量为 0.9 的 SGD 优化器, L2 正则化的权重衰减因子设置为 0.001. 对于学习率策略, 将初始学习率设置为 0.01, 并在训练 40 和 60 个周期后将学习率衰减到 0.001 和 0.000 1, 整个训练过程持续 80 个周期. 在评估过程中, 论文提取了与原始图像和水平翻转版本相对应的特征, 然后将这些特征的平均值作为最终特征. 论文模型在 PyTorch 框架上实现.

3.3 实验结果及分析

实验利用包属性标签进行随机擦除来进行行人图像的预处理, 然后对全局分支和局部分支的特征进行级联. 结果如表 1~3 所示. 表 1 中, A 代表的是基准网络(ResNet-50), B 代表的是在基准网络的基础上添加全局分支和局部分支的改良网络, C 代表的是在改良网络的基础上添加图像包属性随机擦除.

表 1 消融研究实验结果

算法	Market-1501(%)				DukeMTMC-reID(%)			
	Rank-1	Rank-5	Rank-10	mAP	Rank-1	Rank-5	Rank-10	mAP
A	87.6	94.7	96.7	69.9	79.0	89.0	92.1	61.8
B	91.8	97.1	98.1	76.4	84.5	92.4	94.7	70.9
C	93.2	97.6	98.6	81.1	85.0	92.5	94.8	72.7

从表 1 中看出: 在 Market-1501 数据集上, 改良网络的方法(在基准网络的基础上添加全局分支和局部分支)比基准网络的方法在 Rank-1 上提升了 4.2%, 同时 mAP 也提升了 6.5%; 对改良网络进行包属性随机擦除和没有进行包属性随机擦除相比在 Rank-1 上提升了 1.4%, mAP 提升 4.7%; 对于

DukeMTMC-reID 数据集,改良网络的方法比基准网络的方法在 Rank-1 上提升 5.5%,同时 mAP 也提升了 9.1%;对改良网络进行包属性随机擦除和没有进行包属性随机擦除相比在 Rank-1 上提升了 0.5%,mAP 提升 1.8%。总之,通过实验表明论文方法在以上数据集中都有较大的提升,证明论文方法的有效性。

表 2 Market-1501 数据集不同方法试验结果比较

算法	Rank-1/%	Rank-5/%	Rank-10/%	mAP/%
BoW+KISSME ^[15]	44.4	63.9	72.2	20.8
ECN ^[25]	75.1	87.6	91.6	43.0
PAR ^[16]	81.0	92.0	94.7	63.4
SVDNet ^[17]	82.3	92.3	95.2	62.1
Triplet Loss ^[13]	84.9	94.2	95.8	69.1
APR ^[18]	84.3	93.2	95.2	64.7
DPN ^[19]	86.9	95.4	97.0	65.9
LRDNN ^[24]	90.4	—	—	82.8
PCB ^[9]	92.3	97.2	98.2	77.4
TriNet-S ^[26]	92.6	—	—	82.3
VPM ^[27]	93.0	97.8	98.8	80.8
论文	93.2	97.6	98.6	81.1

表 3 DukeMMC-reID 数据集不同方法试验结果比较

算法	Rank-1/%	mAP/%
BoW+KISSME ^[15]	25.1	12.1
LOMO+XQDA ^[20]	30.7	17.0
ECN ^[25]	63.3	40.4
GAN ^[21]	67.6	47.1
APR ^[18]	70.6	51.8
DPN ^[19]	72.8	53.4
TriNet+Era ^[22]	73.0	56.6
MultiScale ^[23]	79.2	60.6
SVDNet+Era ^[22]	79.3	62.4
PCB ^[9]	81.8	66.1
VPM ^[27]	83.6	72.6
TriNet-S ^[26]	84.8	74.4
论文	85.0	72.7

表 2~3 将论文研究的方法与非深度学习方法和深度学习方法分别在两个数据集上的结果进行比较,结果表明论文的方法能够得到更好的实验结果。在 Market-1501 数据集上,Rank-1 值比经典的非深度学习 KISSME 高 48.8%,比深度学习 Triplet Loss 高 8.3%,相比同样通过属性标签和自身 ID 来提高行人的重识别能力的 APR 与 DPN 方法来说,rank-1 分别提高了 8.9% 和 6.3%。在 DukeMTMC-reID 数据集上,Rank-1 和 mAP 相比同样利用了属性标签的 APR 与 DPN 方法 Rank-1 提升了 12% 左右。综上所述,利用属性标签进行随机擦除对数据集进行数据增广,然后通过全局分支和局

部分支的级联能更好的提升网络特征表达能力,提高网络性能.同时,论文方法和近期的一些方法进行比较也具有一定的竞争性.

4 结束语

论文从去除物体遮挡和提升网络特征提取能力的两个方向出发,提出了一种基于属性标签随机擦除与多分支网络的行人重识别的方法.一方面属性标签随机擦除利用包属性标签随机擦除图像限定区域;另一方面同时学习图像的局部特征和全局特征,该网络不仅能有效地提取判别性强的全局特征,还能在特征学习过程中进一步关注局部特征.并且该网络是个端到端的学习过程,并没有增加额外的训练流程,且不引入任何局部定位操作.在 Market-1501、DukeMMC-reID 数据集上实验表明该方法可得到理想的实验结果.

参考文献:

- [1] CHANG X, HOSPEDALES T, XIANG T. Multi-level factorisation net for person re-identification[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2109-2118.
- [2] CHEN D P, XU D, LI H, et al. Group consistent similarity learning via deep crf for person re-identification [C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8649-8658.
- [3] LI W, ZHU X, GONG S. Harmonious attention network for person re-identification[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2285-2294.
- [4] SARFRAZ M S, SCHUMANN A, EBERLE A, et al. A pose-sensitive embedding for person re-identification with expanded cross neighborhood re-ranking [C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2018: 420-429.
- [5] LI W, ZHAO R, XIAO T, et al. Deep filter pairing neural network for person re-identification[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2014: 152-159.
- [6] YI D, LEI Z, LIAO S, et al. Deep metric learning for person re-identification[C]//International Conference on Pattern Recognition, 2014: 34-39.
- [7] ZHONG Z, ZHENG L, CAO D, et al. Re-ranking person re-identification with k-reciprocal encoding[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2017: 3652-3661.
- [8] 金翠, 王洪元, 陈首兵. 基于随机擦除行人对齐网络的行人重识别方法[J]. 山东大学学报(工学版), 2018, 48(6): 71-77.
- [9] SUN Y, ZHENG L, YANG Y, et al. Beyond part models: person retrieval with refined part pooling[C]//European Conference on Computer Vision, 2018: 501-518.
- [10] CHENG D, GONG Y, ZHOU S, et al. Person re-identification by multi-channel parts-based cnn with improved triplet loss function [C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1335-1344.
- [11] SCHROFF F, KALENICHENKO D, PHILBIN J. Facenet: unified embedding for face recognition and clustering[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2015: 815-823.
- [12] VARIOR R R, HALOI M, WANG G. Gated siamese convolutional neural network architecture for human re-identification[C]//European Conference on Computer Vision, 2016: 791-808.
- [13] CHEN W, CHEN X, ZHANG J, et al. Beyond triplet loss: a deep quadruplet network for person re-identification[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2017: 403-412.
- [14] WANG F, XIANG X, CHENG J, et al. Normface: L2 hypersphere embedding for face verification[C]//In 2017 ACM on Multimedia Conference, 2017: 1041-1049.
- [15] ZHENG L, SHEN L, TIAN L, et al. Scalable person re-identification: a benchmark[C]//2015 IEEE International Conference on Computer Vision, 2015: 1116-1124.
- [16] ZHAO L, LI X, ZHUANG Y, et al. Deeply-learned part-aligned representations for person re-identification

- [C]//2017 IEEE International Conference on Computer Vision, 2017: 3239-3248.
- [17] SUN Y, ZHENG L, DENG W, et al. Svdnet for pedestrian retrieval [C]//Proceedings of the 2017 IEEE International Conference on Computer Vision, 2017: 3820-3828.
- [18] LIN Y, ZHENG L, ZHENG Z, et al. Improving person re-identification by attribute and identity learning [EB/OL]. [2017-03-21]. <https://arxiv.org/abs/1703.07220>.
- [19] WU Y, CHEN H, LI S, et al. Person re-identification based on data prior distribution[C]//International Conference on Advanced Control, 2018: 83-89.
- [20] LIAO S, HU Y, ZHU X, et al. Person re-identification by local maximal occurrence representation and metric learning [C]//Proceedings of IEEE Conf on Computer Vision and Pattern Recognition, 2015: 2197-2206.
- [21] ZHENG Z, ZHENG L, YANG Y. Unlabeled samples generated by gan improve the person re-identification baseline in vitro[C]//2015 IEEE International Conference on Computer Vision, 2017: 3774-3782.
- [22] ZHONG Z, ZHENG L, KANG G, et al. Random erasing data augmentation [EB/OL]. [2017-11-16]. <https://arxiv.org/abs/1708.04896>.
- [23] CHEN Y, ZHU X, GONG S, et al. Person re-identification by deep learning multi-scale representations [C]//IEEE International Conference on Computer Vision Workshop, 2017: 2590-2600.
- [24] ZHOU Q Q, ZHONG B, LAN X Y, et al. Lrdnn: local-refining based deep neural network for person reidentification with attribute discerning [C]//Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence, 2019: 1041-1047.
- [25] ZHONG Z, ZHENG L, LUO Z, et al. Invariance matters: exemplar memory for domain adaptive person re-identification[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2019: 598-607.
- [26] ZHANG Y, ZHONG Q, MA L, et al. Learning incremental triplet margin for person re-identification [C]//the Association for the Advance of Artificial Intelligence, 2019: 9243-9250.
- [27] SUN Y, XU Q, LI Y, et al. Perceive where to focus: learning visibility-aware part-level features for partial person re-identification[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2019: 393-402.

(责任编辑 朱夜明)